神经CAE分类

神经CAE对比

PINN（Physics-Informed Neural Networks）物理信息神经网络

传统方法：离散化PDE，求解线性系统。FEM: $\Phi^h u = f \rightarrow Ku = F \rightarrow$ 求解稀疏矩阵

PINN方法：神经网络直接逼近解；NN: u(x,y,z) ≈ NN(x,y,z; θ)；Loss = ||Φ^hNN - f||² + ||边界条件||²

Neural_Operators神经算子

PDE： ∂u/∂t = F(u, ∇u, ∇^2u, ...)，
u(x,y,z,t)是一个"场函数"，直接在函数空间中学习算子G（特定PDE在特定几何上解算子 G）；
"函数到函数"的映射，不依赖离散化；
提取的是物理系统的本征自由度

包含：FNO傅里叶神经算子，AFNO自适应神经算子，DeepONet算子分解网络

当前挑战：不能很好适应复杂几何形状

混合工作流：FNO粗筛（1000个设计），传统CFD精验（50个候选），风洞测试（5个最优）

作用：不是"完全替代"传统CAE，而是在设计迭代阶段提供100-1000倍加速，让工程师能够探索更大的设计空间，找到更优解！

DEEPOnet | FNO

某汽车公司的Neural CAE模型库：

```
├─ 外部气动组（3个模型）
│  ├─ FNO_sedan（轿车族）
│  │  训练：200个轿车外形 × 20工况 = 4000样本
│  │  覆盖：长度4-5m，宽度1.7-1.9m的三厢车
│  ├─ FNO_suv（SUV族）
│  │  训练：150个SUV × 20工况 = 3000样本
│  └─ FNO_truck（卡车族）
│     训练：100个卡车 × 15工况 = 1500样本

├─ 内流组（2个模型）
│  ├─ FNO_manifold（进气歧管）
│  └─ FNO_turbo（涡轮增压器）

├─ 热管理组（4个模型）
│  ├─ FNO_radiator（散热器）
│  ├─ FNO_battery（电池包）
│  ├─ FNO_engine_bay（发动机舱）
│  └─ FNO_hvac（空调系统）

└─ 结构组（5个模型）
   ├─ GNN_crash（碰撞仿真）
   ├─ FNO_nvh（噪声振动）
   ├─ FNO_fatigue（疲劳分析）
   ├─ FNO_topology（拓扑优化）
   └─ GNN_assembly（装配模拟）


总计：14个专门模型


训练成本：
- 每个模型：$50K-150K（数据生成+训练）
- 总投入：~$1M
- 一次性投入


使用收益：
- 每个设计评估：0.1秒（vs 传统1小时）
- 一年优化迭代：10,000次（vs 传统100次）
- ROI：6-12个月回本
```

GNN图神经网络

CAE网格 = 图(Graph)，- 节点 = 网格顶点，- 边 = 单元连接，通过数据获取神经网络的参数；
神经网络"学会"了物理规律，不是写死的公式，而是从数据中学出来的；
与传统方法区别：
　传统FEM：显式求解物理方程（慢但精确）；
　GNN：学习物理规律（快但近似）

适用：任意几何；直接用现有网格；非结构、自适应；支持动态网格

优点：一旦训练好，推理超快（毫秒级）

缺点：需要先训练，泛化有限

作用：不是"完全替代"传统CAE，传统CAE的"涡轮增压器"，不是"替代品"，加速工作流；扩展应用范围；但仍需传统CAE兜底

工具：PyG（基础工具）+ MeshGraphNet （图神经网络的物理仿真应用）
https://github.com/pyg-team/pytorch_geometric/tree/master

Graph Network-based simulators (粒子) | Meshgraphnet

GNN for CAE 完整实施流程

阶段1：问题定义（1-2周）
- □ 明确应用场景（气动/热/结构）
- □ 确定参数空间（长度、角度、载荷...）
- □ 设定精度目标（相对传统CAE）
- □ 评估投入产出比

阶段2：数据生成（2-6周）
- □ 参数采样（LHS，200-500个点）
- □ 自动化脚本开发
- □ 并行CAE求解（利用集群）
- □ 数据清洗和验证
- □ 划分训练/验证/测试集（70%/15%/15%）

推荐：
- 初期：使用粗网格快速生成100个样本
- 训练初版GNN评估可行性
- 确认可行后再生成完整数据集

阶段3：模型开发（2-4周）
- □ 从MeshGraphNet基线开始
- □ 超参数调优（层数、隐藏维度）
- □ 训练策略（学习率、batch size）
- □ 正则化（dropout、weight decay）
- □ 不确定性量化（集成学习）

阶段4：验证与优化（2-3周）
- □ 测试集评估
- □ 与传统CAE对比
- □ 泛化能力测试（外推测试）
- □ 失败案例分析
- □ 迭代改进（增加数据、调整架构）

阶段5：部署（1-2周）
- □ 集成到现有CAE工作流
- □ 用户界面开发
- □ 不确定性警告机制
- □ 回退到传统方法的触发条件
- □ 文档和培训

阶段6：持续改进
- □ 在线学习（新数据持续加入）
- □ 监控预测质量
- □ 用户反馈收集
- □ 定期重新训练

总时间：3-4个月（首次实施）
后续项目：1-2个月（有经验后）

Generative Design生成式设计

让 AI 自动探索海量设计空间，生成满足工程约束的创新方案。

生成式设计流程：
工程师 → 定义需求和约束 → AI自动生成1000+方案 → 筛选最优
（数小时，探索1000+方案）

核心技术路线：
路线 1：进化算法 + CAE（成熟，但慢）
路线 2：AI 生成器 + 快速验证（AI 加速）
路线 3：Diffusion Models扩散模型（最前沿）

生成式设计的范式：
参数化生成（Parameter-driven）；拓扑生成（Topology-driven）；功能生成（Function-driven）

Hybrid_Methods混合方法

结合传统数值方法（FEM/FVM/FDM）的可靠性与AI方法的高效性，取长补短。

模式1：多保真度方法（Multi-Fidelity）：
　步骤1: "Neural Operator粗糙预测（1000个设计，每个0.1秒）",
　步骤2: "筛选Top 10候选方案",
　步骤3: "传统FEM精细验证（10个方案，每个10分钟）"

模式2：AI加速迭代求解器：
传统求解器 + AI加速器，AI快速预测初值（好的初值 → 快速收敛）；传统迭代求解器（从AI初值开始

模式3：物理约束的AI修正：
传统简化模型快速计算+AI学习简化模型的系统性误差；
案例：预测性维护中常用
- 简化物理模型：快速但有系统误差
- AI修正：学习真实数据与模型的偏差

模式4：AI-FEM协同优化：
设计探索阶段:
　　工具: "Neural Operator（粗网格1000节点）",
　　速度: "秒级",
　　方案数: "1000+个候选"

设计验证阶段:
　　工具: "传统FEM（精细网格50万节点）",
　　速度: "分钟到小时级",
　　方案数: "Top 10精选"
　　结果: "既保证速度，又保证精度"

适用场景：
工业关键应用：航空航天、汽车碰撞、核能等（需要高精度验证）
大规模优化：需要评估成千上万个设计方案
实时仿真：数字孪生、硬件在环仿真
数据稀缺场景：物理模型弥补数据不足

优势
精度有保证：传统方法兜底，满足工业标准
速度提升明显：AI加速关键环节，整体提速10-100倍
易获工程师信任：不是纯黑盒，物理模型可解释
数据需求更少：物理约束减少对训练数据的依赖

General Physics Transformer (GPhyT)

https://flowsnr.github.io/blog/physics-foundation-model/

方法	适用场景	速度	精度	泛化能力	工业成熟度	推荐指数
PINN	规则几何、已知PDE	⭐⭐⭐	⭐⭐⭐	⭐⭐	⭐⭐	⭐⭐⭐
Neural Operator	大规模参数扫描	⭐⭐⭐⭐⭐	⭐⭐⭐⭐	⭐⭐⭐⭐	⭐⭐⭐	⭐⭐⭐⭐⭐
GNN	复杂几何、网格适应	⭐⭐⭐⭐	⭐⭐⭐⭐	⭐⭐⭐⭐⭐	⭐⭐⭐	⭐⭐⭐⭐
Generative Design	概念设计、优化	⭐⭐⭐⭐	⭐⭐⭐	⭐⭐⭐	⭐⭐⭐	⭐⭐⭐⭐
混合方法 ⭐新增	工业关键应用	⭐⭐⭐⭐	⭐⭐⭐⭐⭐	⭐⭐⭐⭐	⭐⭐⭐⭐	⭐⭐⭐⭐⭐

工作流程

传统 CAE 工作流程

物理问题 → 数学建模(PDE) → 离散化(FEM/FVM) → 线性系统求解 → 结果
　↓　　↓　　↓　　↓　　↓
几何体　$\nabla^2 u=f$　网格生成Ku=F　矩阵求解器　后处理

时间成本：分钟到小时（每次都要重新求解）
优势：精确、可靠、符合物理定律
劣势：计算密集、参数扫描慢

神经 CAE 工作流程

离线阶段（一次性）：
大量仿真数据 → 训练神经网络/算子 → 学习物理规律
　↓　　↓　　↓
θ = argmin L　反向传播　通用求解器

在线阶段（可重复使用）：
新的参数/几何 → 神经网络推理 → 瞬时输出结果
　↓　　↓　　↓
输入条件　前向传播　毫秒级响应

时间成本：推理0.1秒（训练一次，使用无数次）
优势：极快、可泛化、适合优化迭代
劣势：精度依赖训练、黑盒特性

企业布局

产业化时间表：

2024-2025：早期采用者（科技公司、研究机构）

2025-2027：行业试点（汽车、航空头部企业）

2027-2030：大规模部署（成为标准工具）

2030+：主流范式（AI为主，传统为辅

```
技术深度 vs 市场广度矩阵

技术深度
  ↑
  |        Google DeepMind
  |              ●
  |
  |                    NVIDIA PhysicsNeMo
  |                          ●
  |
  |    Monolith AI
  |        ●
  |
  |                         Neural Concept
  |                              ●
  |
  |             传统CAE厂商（ANSYS, Siemens）
  |                    ●
  |
  └──────────────────────────→
                市场覆盖广度

象限解读：
- 左上（DeepMind）：技术引领，不追求商业化
- 右上（NVIDIA）：技术+生态双强
- 左中（Monolith）：深耕细分领域
- 右中（Neural Concept）：产品化好，技术较浅
- 右下（传统厂商）：市场强，AI转型慢
```

DeepMind生态:
成熟领域:
生物制药（AlphaFold → 药物发现），
天气预报（GraphCast → 气象局试用），
学术研究（JAX → 数千篇论文）

试点领域:
CFD优化（MeshGraphNets → 航空公司POC），
材料发现（GNoME → 实验室）

商业模式:
技术授权、云服务（通过Google），
营收: 间接（Google整体营收），
企业客户: 主要通过Google Cloud接触

NVIDIA生态:

成熟领域:
机器人仿真（Isaac → Tesla, Amazon等）
数字孪生（Omniverse → BMW, Lockheed）
CAE加速（Modulus → 能源、制造）

试点领域:
气候模拟（Earth-2 → 政府合作）
生物计算（BioNeMo → 制药公司）

商业模式: "硬件销售 + 软件订阅",
营收: 直接
企业客户: 数千家（Fortune 500覆盖广）

关键差异:

DeepMind:
- 技术领先3-5年
- 但工业化路径不清晰
- 更像"技术供应商"

NVIDIA:
- 技术跟随DeepMind 1-2年
- 但产品化、落地能力强
- 更像"解决方案提供商